به نام خدا

دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق

تمرین دوم

نام و نام خانوادگی	فاطمه جلیلی – سالار صفردوست
شماره دانشجویی	۸۱۰۱۹۹۳۹۸ -۸۱۰۱۹۹۴۵۰
تاریخ ارسال گزارش	۱۴۰۲/۹/۲

فهرست

شکل‌ها

پاسخ ۱- تجزیه و تحلیل احساسات صورت مبتنی بر CNN

2-1. پیش پردازش تصاویر و Data Augmentation

پس از خواندن داده های از پوشه آن ها را در ماتریس x_train و y_train ذخیره می کنیم که سایز آن ها در کد به شکل زیر گزارش شده است:

```
print(x.shape)
print(y.shape)
print(x_tune.shape)
print(y_tune.shape)
```

```
(8000, 128, 128, 3)
(8000,)
(1600, 128, 128, 3)
(1600,)
```

شکل۱-۱. ابعاد داده های train و test

در ادامه پس از نرمال کردن داده ها برای data augmentation مطابق آنچه در مقاله گفته شده با استفاده از tf.keras.preprocessing.image.ImageDataGenerator داده ها را به صورت رندوم تا ۲۰ درجه می چرخانیم ، در جهت x, y تا ۱۰ درصد shift می دهیم و در جهت flip x می کنیم و دیتا های جدید را به ماتریس train قبل append می کنیم.

```
print(x_train.shape)
print(y_train.shape)
```

```
(7680, 128, 128, 3)
(7680,)
```

شکل۱-۲. ابعاد داده های train پس از augmentation

به طور رندوم یک عکس augment شده را انتخاب کرده و آن را نشان می دهیم، از کشیدگی های اطراف تصویر می توان متوجه شد که تصویر rotate شده است. در کنار تصویر augment شده تصویر اصلی نیز در زیر گزارش شده است:

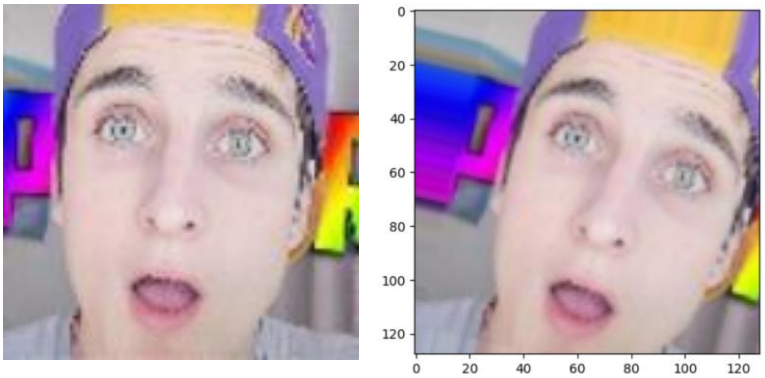

شکل۱-۳. مثالی از داده های augment شده در سمت راست و داده اصلی در سمت چپ

در ادامه به صورت رندوم ۲۰٪ از داده های train را جدا کرده و به عنوان داده test در ماتریس های مربوطه ذخیره می کنیم.

3-1. پیاده سازی مدل AlexNet

مطابق لایه های گفته شده در مقاله مدل را تعریف می کنیم:

Model:

Layer	Output Shape	Param #
conv2d	(None, 128, 128, 16)	3904
batch_normalization	(None, 128, 128, 16)	64
relu	(None, 128, 128, 16)	0
max_pooling2d	(None, 64, 64, 16)	0
gaussian_dropout	(None, 64, 64, 16)	0
conv2d	(None, 64, 64, 32)	25120
batch_normalization	(None, 64, 64, 32)	128
relu	(None, 64, 64, 32)	0
max_pooling2d	(None, 32, 32, 32)	0
gaussian_dropout	(None, 32, 32, 32)	0
conv2d	(None, 32, 32, 64)	51264
batch_normalization	(None, 32, 32, 64)	256
relu	(None, 32, 32, 64)	0
max_pooling2d	(None, 16, 16, 64)	0
gaussian_dropout	(None, 16, 16, 64)	0
conv2d	(None, 16, 16, 128)	73856
batch_normalization	(None, 16, 16, 128)	512
relu	(None, 16, 16, 128)	0
max_pooling2d	(None, 8, 8, 128)	0

```
 gaussian_dropout                (None, 8, 8, 128)         0
 conv2d                          (None, 8, 8, 128)         147584
 batch_normalization             (None, 8, 8, 128)         512
 relu                            (None, 8, 8, 128)         0
 max_pooling2d                   (None, 4, 4, 128)         0
 gaussian_dropout_4              (None, 4, 4, 128)         0
 flatten                         (None, 2048)              0
 dense                           (None, 1024)              2098176
 dropout                         (None, 1024)              0
 Dense                           (None, 1024)              1049600
 Dropout                         (None, 1024)              0
 Dense                           (None, 8)                 8200

=================================================================
Total params: 3,459,176
Trainable params: 3,458,440
Non-trainable params: 736
```

از Adam optimizer با پارامتر های

```
learning_rate=0.0005,

beta_1=0.9,

beta_2=0.999,

epsilon=1e-8
```

مطابق مقاله استفاده می کنیم ، همچنین برای loss از SparseCategoricalCrossentropy استفاده می کنیم.

با استفاده از ۳۲ ایپاک و batch size ۸۰ نتایج زیر روی داده train و test بدست می آید:

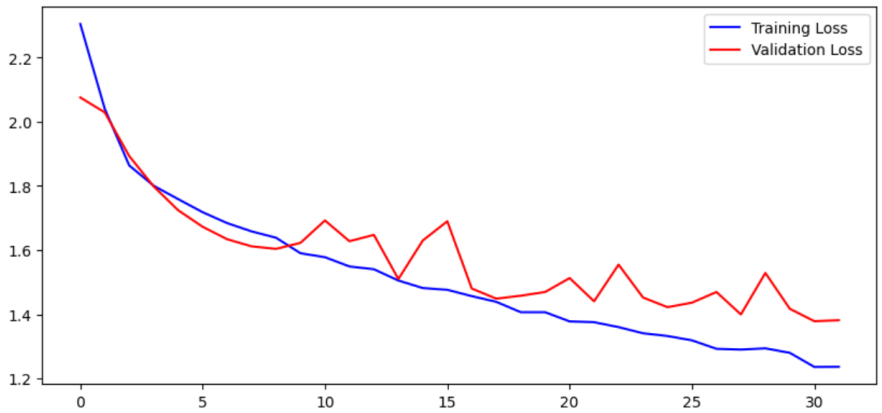

شکل۱-۴. Loss روی داده train (آبی رنگ) و test (قرمز رنگ)

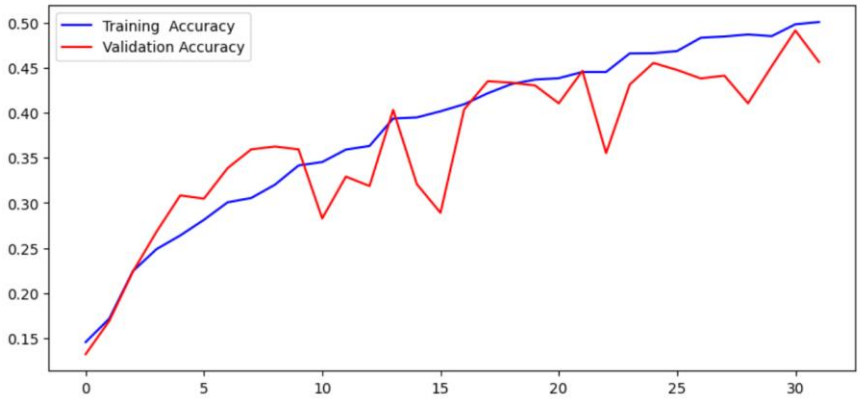

شکل۱-۵. accuracy روی داده train (آبی رنگ) و test (قرمز رنگ)

مطابق نتایج بدست آمده دقت روی داده tain و تست به ترتیب به حدود ۵۰ و ۴۵ درصد می رسد که در مقایسه با مقاله که دقت ۵۶ درصد دارد کمی فاصله دارد.

برای fine tune لایه های قبل falatten را فیکس می کنیم و ۵ لایه آخر شامل ۴ dense و یک dropout را قابل tune تعیین می کنیم و مدل را روی داده های tune مجدد train می کنیم، نتایج مطابق زیر بدست می آیند:

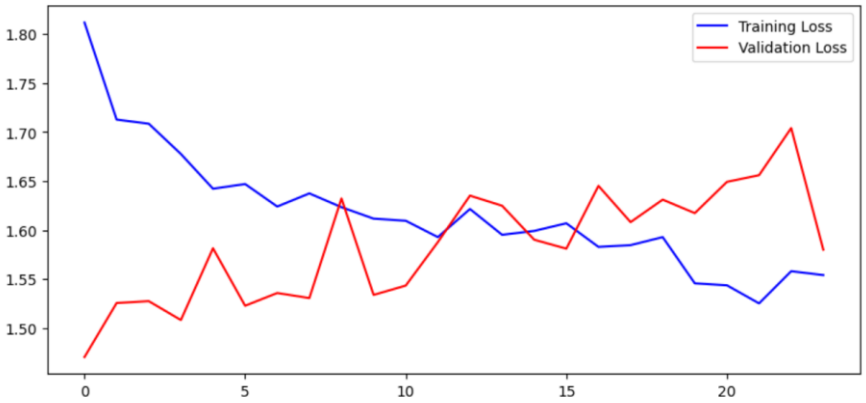

شکل۱-۶. Loss روی داده train (آبی رنگ) و test (قرمز رنگ) برای داده tune

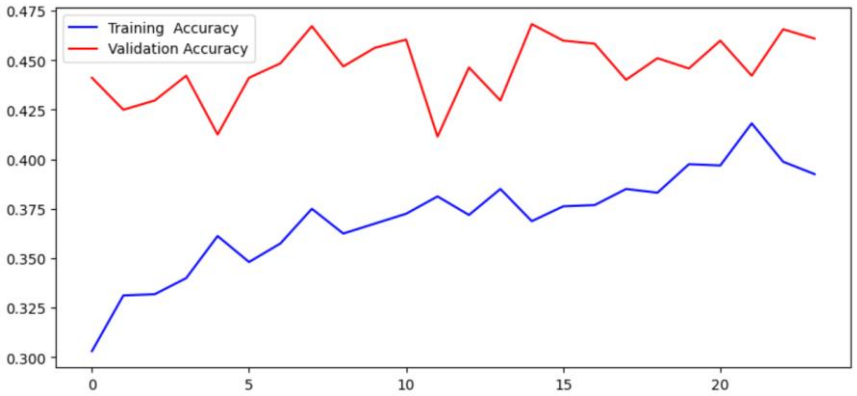

شکل۱-۷. accuracy روی داده train (آبی رنگ) و test (قرمز رنگ) برای داده tune

این بار دقت روی داده train و test به ترتیب به حدود ۳۹ درصد و ۴۶ درصد می رسد به این معنا که شبکه نتوانسته به دلیل ترین شدن تنها چند لایه آخر به خوبی به داده جدید tune فیت شود منتهی در مقایسه با دقت روی داده train به دلیل وزن ها فریز شده لایه های قبل که از داده بزرگ قبلی بدست آمده عملکرد خوبی روی داده test دارد.

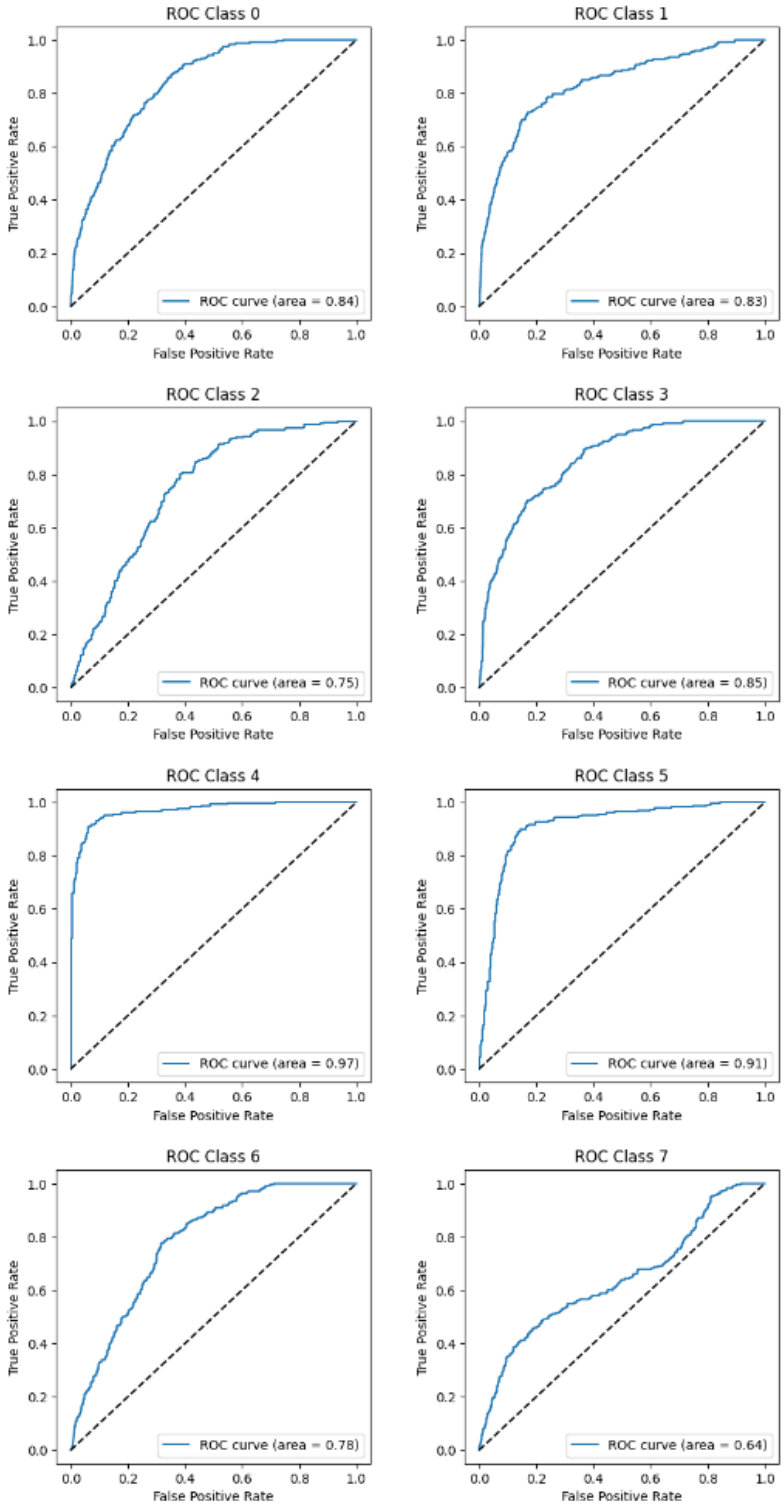

شکل ۱-۸. نمودار های ROC برای کلاس های مختلف

نمودارها ی ROC کیفیت پیش‌بینی شبکه را برای کلاس‌های مختلف به صورت جداگانه بررسی می‌کند و هر میزان قوس نمودار رو به بالا بیشتر باشد(مساحت بیشتر) نمایانگر بهتر بودن شبکه در تشخیص کلاس است.

بنابراین طبق این معیار این شبکه در تشخیص کلاس‌های ۴ و ۵(خوشحال و بی‌حالت) با فاصله بهتر عمل کرده است و در تشخیص کلاس ۷ (شگفت‌زدگی) ضعیف بوده است و تشخیص‌های مثبت درست کمی داشته است.

```
Precision for class 0: 0.419
Recall for class 0: 0.256
F1-score for class 0: 0.318

Precision for class 1: 0.471
Recall for class 1: 0.559
F1-score for class 1: 0.511

Precision for class 2: 0.319
Recall for class 2: 0.185
F1-score for class 2: 0.234

Precision for class 3: 0.445
Recall for class 3: 0.54
F1-score for class 3: 0.488

Precision for class 4: 0.748
Recall for class 4: 0.866
F1-score for class 4: 0.803

Precision for class 5: 0.51
Recall for class 5: 0.745
F1-score for class 5: 0.606

Precision for class 6: 0.272
Recall for class 6: 0.405
F1-score for class 6: 0.326

Precision for class 7: 0.365
Recall for class 7: 0.099
F1-score for class 7: 0.155
```

شکل۱-۹. مقادیر precision،recall و F1-score برای کلاس های مختلف

معیار Precision: این معیار نسبت تعداد تشخیص‌های مثبت درست به تعداد تشخیص‌های مثبت را نشان می‌دهد. در شکل دیده می شود که کلاس ۴ (خوشحالی) با فاصله بهتر است. در کلاس ۷ (شگفت‌زدگی) بدترین عدد وجود دارد که نشان می‌دهد تقریباً ۰.۳۶ تشخیص‌های شگفت‌زدگی درست بوده است.

معیار Recall: این معیار نسبت تعداد تشخیص‌های مثبت درست به تعداد مثبت‌های واقعی را نشان می‌دهد. در شکل مجدداً دیده که کلاس ۴ (خوشحالی) با فاصله بهتر است. در کلاس ۷ (شگفت‌زدگی) بدترین عدد وجود دارد که نشان می‌دهد تنها توانسته‌ایم ۰.۱۵۵ درصد مثبت‌های واقعی را تشخیص دهیم.

معیار F1-score: این معیار به گونه‌ای می‌باشد که هر دوی Precision و Recall را در نظر می‌گیرد. بهترین کلاس برای پیش‌بینی به دید این معیار کلاس ۴ و بدترین کلاس آن‌ها کلاس ۷ بوده است.

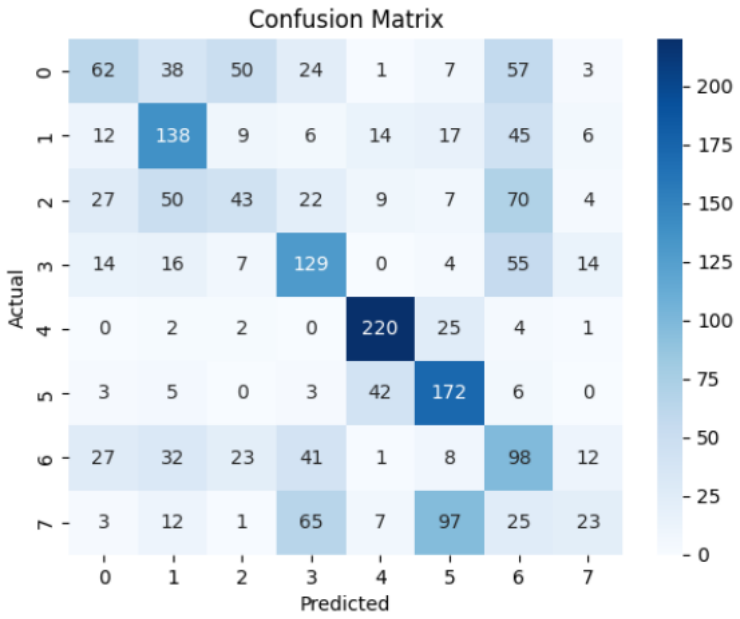

شکل۱-۱۰. Confusion Matrix

با رسم ماتریس آشفتگی هم نتایج به نحو دیگری نشان داده می شوند که برای هر کلاس تعداد لیبل های درست را و تعداد لیبل های غلط تشخیص داده شده به نحوی که این لیبل به غلط کدام کلاس تشخیص داده شده را نشان می دهد ، در این شکل هم نشان داده می شود کلاس ۴ با ۲۲۰ تشخیص درست و ۳۴ تشخیص غلط که ۲۵ تا از آن ها را به غلط کلاس ۵ و ۴ تا از آن ها را به غلط کلاس ۴ و ... تشخیص داده است.

پاسخ ۲ – پیاده سازی مدل VGGNet

2-1. مدل VGGNet

معماری شبکه را به صورت گفته شده پیاده‌سازی می‌کنیم.

برای آموزش شبکه از همان قطعه کد مربوط به آگمنت کردن دیتا در سوال ۱ استفاده می‌کنیم.

برای به دست آوردن پاسخ مناسب batch_size=80 و epochs=32 انتخاب شد و همچنین لرنینگ ریت به 0.0005 کاهش یافت. سایر پارامترهای شبکه مشابه مقاله تنظیم شد.

نمودار آموزش شبکه روی دیتای آموزش:

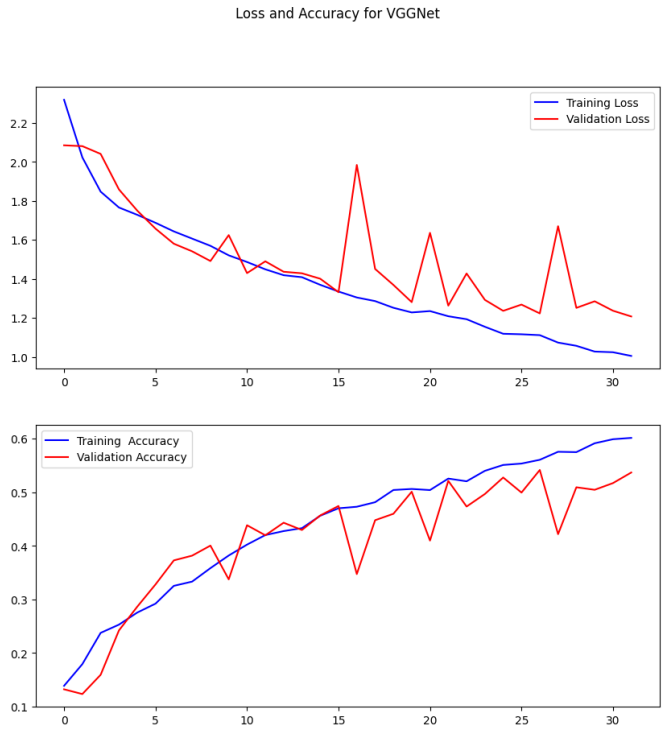

شکل ۲-۱. نمودار تابع هزینه و دقت شبکه VGGNet پس از آموزش

```
y_pred_prob = tf.nn.softmax(VGGNet.predict(x_test))
y_pred = np.argmax(y_pred_prob, axis=1)

accuracy = accuracy_score(y_test, y_pred)
print("Total VGGNet accuracy:", accuracy)
```

```
[10]
...  60/60 [==============================] - 1s 9ms/step
Total VGGNet accuracy: 0.5375
```

شکل ۲-۲. دقت شبکه VGGNet پس از آموزش

پس از آموزش با استفاده از دیتاست تیون، شبکه روی این دیتا مجددا آموزش دید.

برای به دست آوردن پاسخ مناسب batch_size=16 و epochs=24 انتخاب شد و همچنین لرنینگ ریت به 0.0005 کاهش یافت. سایر پارامترهای شبکه مشابه مقاله تنظیم شد.

نمودار بهبود شبکه با دیتای تیون:

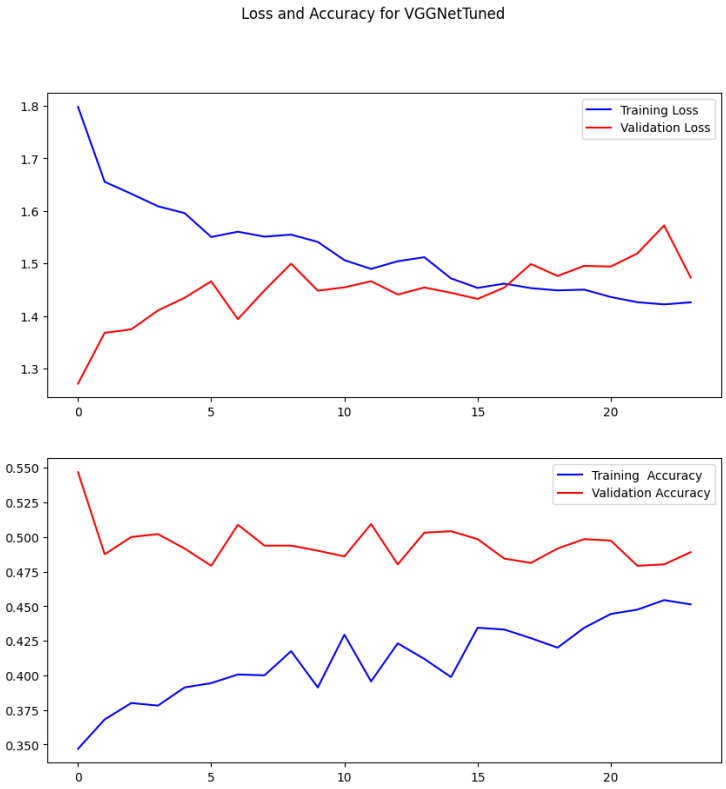

شکل ۲-۳. نمودار تابع هزینه و دقت شبکه VGGNet پس از بهبود

```
[15]
    y_tune_pred_prob = tf.nn.softmax(VGGNetTuned.predict(x_test))
    y_tune_pred = np.argmax(y_tune_pred_prob, axis=1)

    accuracy_tune = accuracy_score(y_test, y_tune_pred)
    print("Total AlexNetTuned accuracy:", accuracy_tune)

...  60/60 [==============================] - 1s 9ms/step
     Total AlexNetTuned accuracy: 0.4890625
```

شکل ۲-۴. دقت شبکه VGGNet پس از بهبود

همانگونه که قابل مشاهده است، آموزش شبکه با دیتای آموزش به شکلی خوب باعث کاهش نمودار هزینه و افزایش درصد موفقیت در هر دو دیتاست ترین و تست شده و در نهایت شاهد ۵۳.۷۵ درصد موفقیت روی تست می‌باشیم.

با آموزش مجدد شبکه روی دیتای تیون مقدار تابع هزینه برای دیتای تیون کاهش و درصد موفقیت افزایش یافته اما برای دیتای تست اندکی تغییرات منفی را شاهد هستیم.

این امر می‌تواند به دلیل تفاوت میان دیتای تست و تیون، ناکافی بودن دیتای تیون برای بهبود شبکه و همچنین فریز کردن لایه‌های کانولوشنال شبکه باشد. اما در کل با توجه به آشنا شدن شبکه به دیتای تیون و عدم تغییر زیاد آن بر دقت شبکه، می‌توان گفت که تغییر مثبتی را شاهد بوده‌ایم.

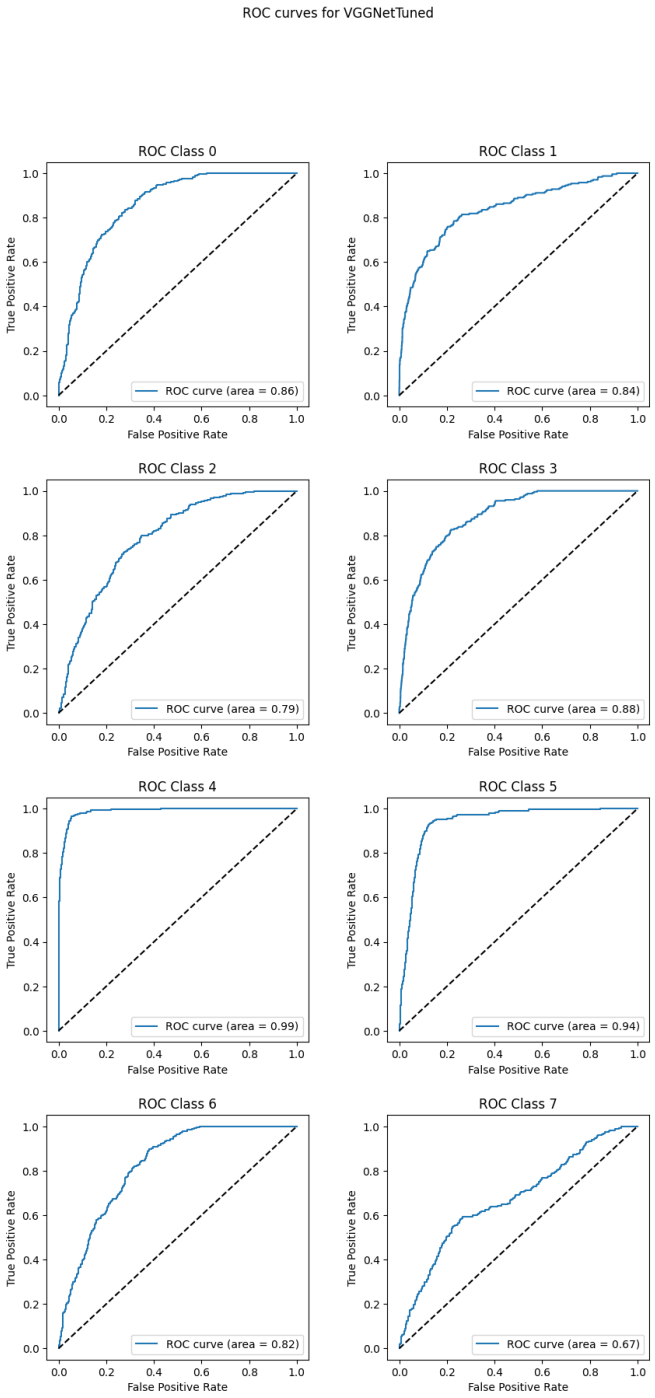

شکل ۲-۵. نمودارهای ROC برای هر کلاس در شبکه VGGNet

این نمودارها کیفیت پیش‌بینی شبکه را برای کلاس‌های مختلف به صورت جداگانه بررسی می‌کند و هر میزان قوس نمودار رو به بالا بیشتر باشد(مساحت بیشتر) نمایانگر بهتر بودن شبکه در تشخیص کلاس است.

بنابراین طبق این معیار این شبکه در تشخیص کلاس‌های ۴ و ۵(خوشحال و بی‌حالت) با فاصله بهتر عمل کرده است و در تشخیص کلاس ۷ (شگفت‌زدگی) ضعیف بوده است و تشخیص‌های مثبت درست کمی داشته است.

```
Precision for class 0: 0.413
Recall for class 0: 0.328
F1-score for class 0: 0.366

Precision for class 1: 0.593
Recall for class 1: 0.43
F1-score for class 1: 0.499

Precision for class 2: 0.343
Recall for class 2: 0.338
F1-score for class 2: 0.341

Precision for class 3: 0.558
Recall for class 3: 0.47
F1-score for class 3: 0.51

Precision for class 4: 0.79
Recall for class 4: 0.933
F1-score for class 4: 0.856

Precision for class 5: 0.495
Recall for class 5: 0.807
F1-score for class 5: 0.613

Precision for class 6: 0.337
Recall for class 6: 0.388
F1-score for class 6: 0.36

Precision for class 7: 0.28
Recall for class 7: 0.198
F1-score for class 7: 0.232
```

شکل ۲-۶. معیارهای Precision، Recall و F1-score شبکه VGGNet

معیار Precision: این معیار نسبت تعداد تشخیص‌های مثبت درست به تعداد تشخیص‌های مثبت را نشان می‌دهد. در شکل دیده که کلاس ۴ (خوشحالی) با فاصله بهتر است. در کلاس ۷ (شگفت‌زدگی) بدترین عدد وجود دارد که نشان می‌دهد تقریباً ۰.۳ تشخیص‌های شگفت‌زدگی درست بوده است.

معیار Recall: این معیار نسبت تعداد تشخیص‌های مثبت درست به تعداد مثبت‌های واقعی را نشان می‌دهد. در شکل مجدداً دیده که کلاس ۴ (خوشحالی) با فاصله بهتر است. در کلاس ۷ (شگفت‌زدگی) بدترین عدد وجود دارد که نشان می‌دهد تنها توانسته‌ایم ۰.۱۹۸ درصد مثبت‌های واقعی را تشخیص دهیم.

معیار F1-score: این معیار به گونه‌ای می‌باشد که هر دوی Precision و Recall را در نظر می‌گیرد.

بهترین کلاس برای پیش‌بینی به دید این معیار کلاس ۴ و بدترین کلاس آن‌ها کلاس ۷ بوده است.

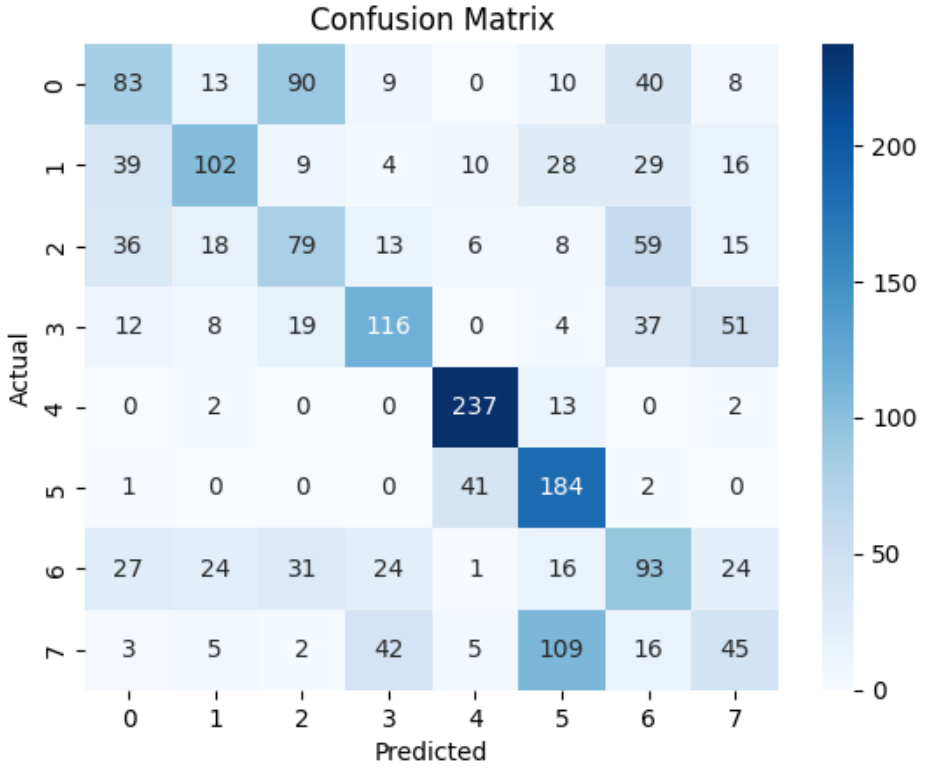

شکل ۲-۷. ماتریس Confusion **شبکه** VGGNet

به طور کلی می‌توانیم نتیجه بگیریم که شبکه‌ی VGGNet شبکه‌ی بهتری نسبت به AlexNet برای تشخیص احساسات بوده است و درصد موفقیت آن در معیارهای مختلف بالاتر بوده است.

البته لازم به ذکر است که پیچیدگی شبکه‌ی VGGNet از لحاظ تعداد پارامترها اندکی بیشتر از AlexNet بوده است.

پاسخ ۳ – تشخیص بیماران مبتلا به کووید با استفاده از عکس ریه

2-3. جمع آوری داده و پردازش تصویر

پس از خواندن داده های از پوشه و هم سایز کردن عکس ها به اندازه (150, 150) که در مقاله گفته شده آن ها را در ماتریس x_train و y_train ذخیره می کنیم که سایز آن ها در کد به شکل زیر گزارش شده است:

```
x_train shape: (148, 150, 150, 3)
Y_train shape: (148,)
x_test shape: (40, 150, 150, 3)
y_test shape: (40,)
```

شکل ۳-۱. ابعاد داده های train و test

در ادامه پس از نرمال کردن داده ها برای data augmentation مطابق آنچه در مقاله گفته شده همه ی عکس ها train را یکدور flip می کنیم، عکس اولیه را ۹۰ درجه ، ۱۸۰ درجه و ۲۷۰ درجه می چرخانیم لذا در کل تعداد عکس های ما 5 برابر می شود. طبق گفته سوال اینکار را به ترتیب انجام می دهیم تا با overfit مواجه نشویم یعنی پس از augmentation در ماتریس x_train ، ۱۴۸ داده اول داده های اصلی ، ۱۴۸ داده دوم داده های flip شده ، ۱۴۸ داده سوم داده های ۹۰ درجه چرخیده و ... است.

```
augmented x_train shape: (740, 150, 150, 3)
augmented y_train shape: (740, 1)
```

شکل ۳-۲. ابعاد داده های train پس از augmentation

به طور رندوم یک عکس در داده های آموزش را انتخاب کرده و ورژن اصلی آن را در کنار ورژن های flip شده و rotate شده آن نشان می دهیم:

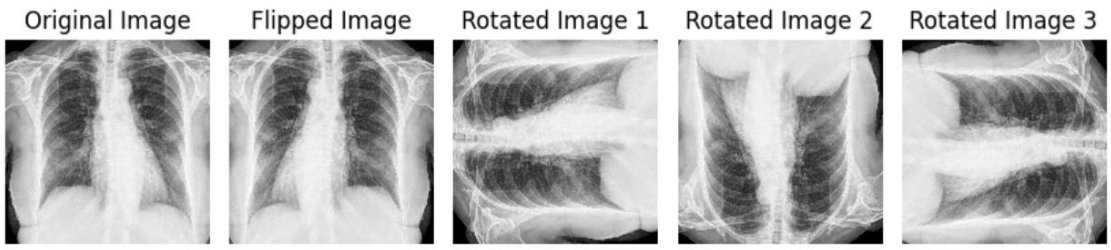

شکل ۳-۳. مثالی از داده های augment شده

در ادامه مطابق آنچه در مقاله گفته شده به صورت رندوم ۲۵٪ از داده های train را جدا کرده و به عنوان داده validation در ماتریس های مربوطه ذخیره می کنیم.

3-3. آموزش شبکه

مطابق لایه های گفته شده در مقاله مدل را تعریف می کنیم:

```
Model:
_________________________________________________________________
 Layer (type)                 Output Shape              Param #
=================================================================
 conv2d                      (None, 150, 150, 64)      1792
 batch_normalization         (None, 150, 150, 64)      256
 max_pooling2d               (None, 75, 75, 64)        0
 dropout                     (None, 75, 75, 64)        0
 conv2d                      (None, 75, 75, 64)        36928
 batch_normalization         (None, 75, 75, 64)        256
 max_pooling2d               (None, 37, 37, 64)        0
 dropout                     (None, 37, 37, 64)        0
 conv2d                      (None, 37, 37, 128)       73856
 batch_normalization         (None, 37, 37, 128)       512
 max_pooling2d               (None, 18, 18, 128)       0
 dropout                     (None, 18, 18, 128)       0
 conv2d                      (None, 18, 18, 128)       147584
 batch_normalization         (None, 18, 18, 128)       512
 max_pooling2d               (None, 9, 9, 128)         0
 dropout                     (None, 9, 9, 128)         0
 conv2d                      (None, 9, 9, 256)         295168
 batch_normalization         (None, 9, 9, 256)         1024
 max_pooling2d               (None, 4, 4, 256)         0
 dropout                     (None, 4, 4, 256)         0
 conv2d                      (None, 4, 4, 256)         590080
 batch_normalization         (None, 4, 4, 256)         1024
 max_pooling2d               (None, 2, 2, 256)         0
 dropout                     (None, 2, 2, 256)         0
 flatten                     (None, 1024)              0
 dense                       (None, 512)               524800
 batch_normalization         (None, 512)               2048
 dense                       (None, 256)               131328
 batch_normalization         (None, 256)               1024
 dense                       (None, 1)                 257

=================================================================
Total params: 1,808,449
Trainable params: 1,805,121
Non-trainable params: 3,328
```

از Adam optimizer با پارامتر های

```
learning_rate=0.01,

beta_1=0.9,

beta_2=0.999,

epsilon=1e-8
```

استفاده می کنیم ، همچنین برای loss از BinaryCrossentropy استفاده می کنیم.

با استفاده از ۳۰ ایپاک و batch size ۲۵ نتایج زیر روی داده train و validation بدست می آید:

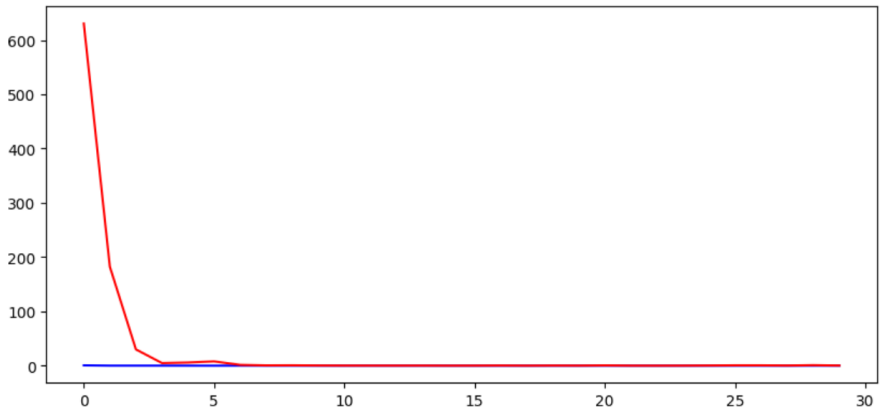

شکل ۳-۴. Loss روی داده train (آبی رنگ) و validation (قرمز رنگ)

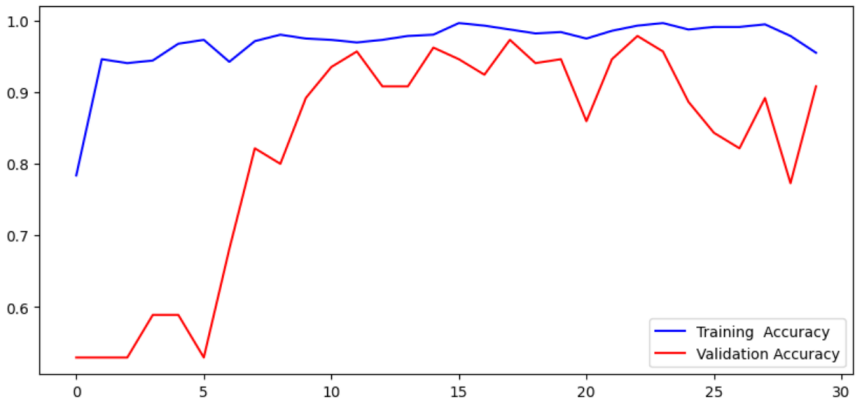

شکل ۳-۵. accuracy روی داده train (آبی رنگ) و validation (قرمز رنگ)

مطابق نمودار ها loss برای هر دو داده train و validation به مقدار بسیار کمی به ترتیب حدود ۰.۱۳ و حدود ۰.۳۴ می رسد.

Accuracy برای داده train تا ۰.۹۹ و برای داده validation تا ۰.۹۸ بالا می رود منتها در هر ایپاک منظم روند افزایشی ندارد ولی در کل به ازای تعداد ایپاک های بالا روند افزایشی مطلوبی دارد.

4-3. ارزیابی شبکه

نتایج بدست آمده روی داده تست مطابق زیر است:

```
2/2 [==============================] - 0s 18ms/step
Accuracy: 1.0
Precision: 1.0
Specificity: 1.0
Sensitivity: 1.0
F1 Score: 1.0
```

شکل۳-۶. نتایج روی داده test

به ازای initialization های مختلف در آموزش شبکه نتایجی بین ۹۰ تا ۱۰۰ درصد بر روی داده test بدست می آمد که در فوق حالتی که همه داده های test درست تشخیص داده شدند ذخیره و گزارش شده است.

برای محاسبه معیار های خواسته شده طبق فرمول از مقادیر true positive, true negative, false positive , false negative مطابق زیر استفاده می کنیم:

```
TP = tf.math.count_nonzero(y_hat * y_test)
TN = tf.math.count_nonzero((y_hat - 1) * (y_test - 1))
FP = tf.math.count_nonzero(y_hat * (y_test - 1))
FN = tf.math.count_nonzero((y_hat - 1) * y_test)

precision = TP / (TP + FP)
specificity = TN / (TN + FP)
sensitivity = TP / (TP + FN)
f1_score = 2 * precision * sensitivity / (precision + sensitivity)
```

شکل۳-۷. نحوه محاسبه معیار های ارزیابی شبکه

مطابق نتایج بدست آمده شبکه مطابق مقاله روی داده test همه ی label ها را به درستی تشخیص داده است و لذا معیار های ارزیابی شبکه همگی در مقدار ماکسیمم خود یعنی ۱ قرار دارند.

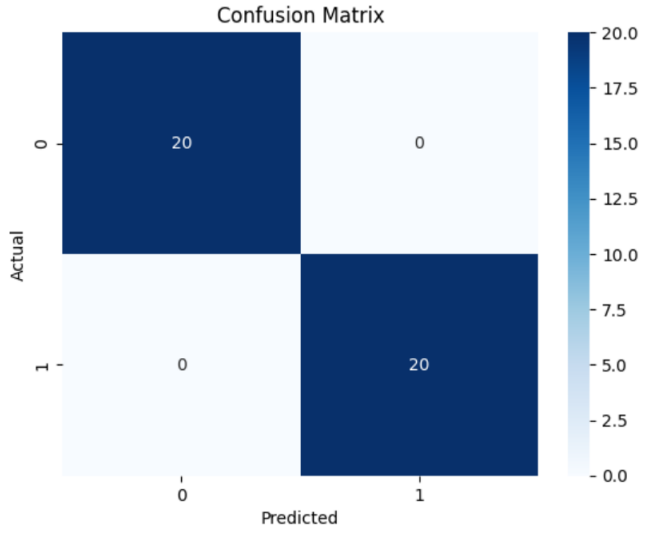

شکل۳-۸. Confusion Matrix برای داده تست

با رسم ماتریس آشفتگی هم نتایج به نحو دیگری ارزیابی می شوند که نشان داده می شود ۲۰ داده با لیبل ۰ همگی به درستی ۰ تشخیص داده شده اند و ۲۰ داده دیگر با لیبل ۱ همگی به درستی ۱ تشخیص داده شده اند.

5-3. ارزیابی شبکه (امتیازی)

در قسمت های فوق نتایج شبکه با ۶ لایه کانولوشن نشان داده شد ، در ادامه دقت داده test را برای شبکه با ۱ تا ۵ لایه کانولوشن تکرار می کنیم.

۵ بار جداگانه مدل را تعریف کرده و با پارامتر های مشابه قسمت قبل آموزش می دهیم (کد تعریف شبکه در یک for به ازای convolution_num متغیر نوشته شد منتها به دلیل حجم محاسبات بالا قابل run شدن نبود لذا مدل ها به تفکیک ۵ بار نوشته شدند)

- شبکه با ۵ لایه کانولوشن:

```
Epoch 29/30
23/23 [==============================] - 2s 84ms/step - loss: 0.1424 - accuracy: 0.9586 - val_loss: 0.4975 - val_accuracy: 0.8919
Epoch 30/30
23/23 [==============================] - 2s 85ms/step - loss: 0.0849 - accuracy: 0.9658 - val_loss: 0.3197 - val_accuracy: 0.9405
Accuracy with 5 Conv2D layers: 1.0
```

شکل۳-۹. دقت شبکه با ۵ لایه کانولوشن

- شبکه با ۴ لایه کانولوشن:

```
Epoch 29/30
23/23 [==============================] - 2s 90ms/step - loss: 0.0434 - accuracy: 0.9874 - val_loss: 0.1814 - val_accuracy: 0.9514
Epoch 30/30
23/23 [==============================] - 2s 99ms/step - loss: 0.0111 - accuracy: 0.9982 - val_loss: 0.1343 - val_accuracy: 0.9784
Accuracy with 4 Conv2D layers: 0.96875
```

شکل۳-۱۰. دقت شبکه با ۴ لایه کانولوشن

- شبکه با ۳ لایه کانولوشن:

```
Epoch 29/30
23/23 [==============================] - 2s 87ms/step - loss: 0.0108 - accuracy: 0.9964 - val_loss: 0.6836 - val_accuracy: 0.8703
Epoch 30/30
23/23 [==============================] - 2s 87ms/step - loss: 0.0156 - accuracy: 0.9946 - val_loss: 0.3240 - val_accuracy: 0.9568
Accuracy with 3 Conv2D layers: 0.984375
```

شکل۳-۱۱. دقت شبکه با ۳ لایه کانولوشن

- شبکه با ۲ لایه کانولوشن:

کد این قسمت مطابق قسمت های قبل در نوت بوک آپلود شده قابل مشاهده است منتها به دلیل اینکه بدون کاهش ابعاد کافی ماتریس های ورودی آن ها مستقیم به لایه fully connected داده می شوند حجم محاسبات و memory لازم بسیار بالاست که GPU در اختیار ما (6 gigabyte) قادر به اختصاص این میزان حافظه نبود لذا با ارور مواجه می شدیم که در نوت بوک آپلود شده قابل مشاهده است.

- شبکه با ۱ لایه کانولوشن:

مطابق حالت قبل در این قسمت هم به دلایل توضیح داده شده با ارور حافظه مواجه شدیم.